Тональность русскоязычных отзывов: рекуррентные нейросети

Финальный проект по дисциплине «Нейронные сети»

Подольский Филипп, магистратура ПМИ, ФМИ ПГНИУ
Преподаватель — И. П. Селетков · Пермь, 2026

Актуальность и проблема

Актуальность. Отзывы об отелях, клиниках, ресторанах и банках — поток текста, который вручную не прочитать. Автоматическая оценка тональности нужна, чтобы отслеживать качество сервиса и быстро находить жалобы.

Исходная постановка — практика 10. BiLSTM по словам, обрезка текста до 50 слов, сравнение по одному запуску. Словарь и обучение строились по всему набору, включая валидацию и тест.

Проблема. Неизвестно, какие решения действительно влияют на качество — тип ячейки, длина текста, размер сети, оптимизатор, регуляризация, предобученные эмбеддинги — и выигрывает ли рекуррентная сеть у простых методов.

48 212

отзывов, три класса поровну: нейтральные, положительные, отрицательные

0,99

val accuracy в практике 10 — не оценка качества: валидация входила в обучение

66 %

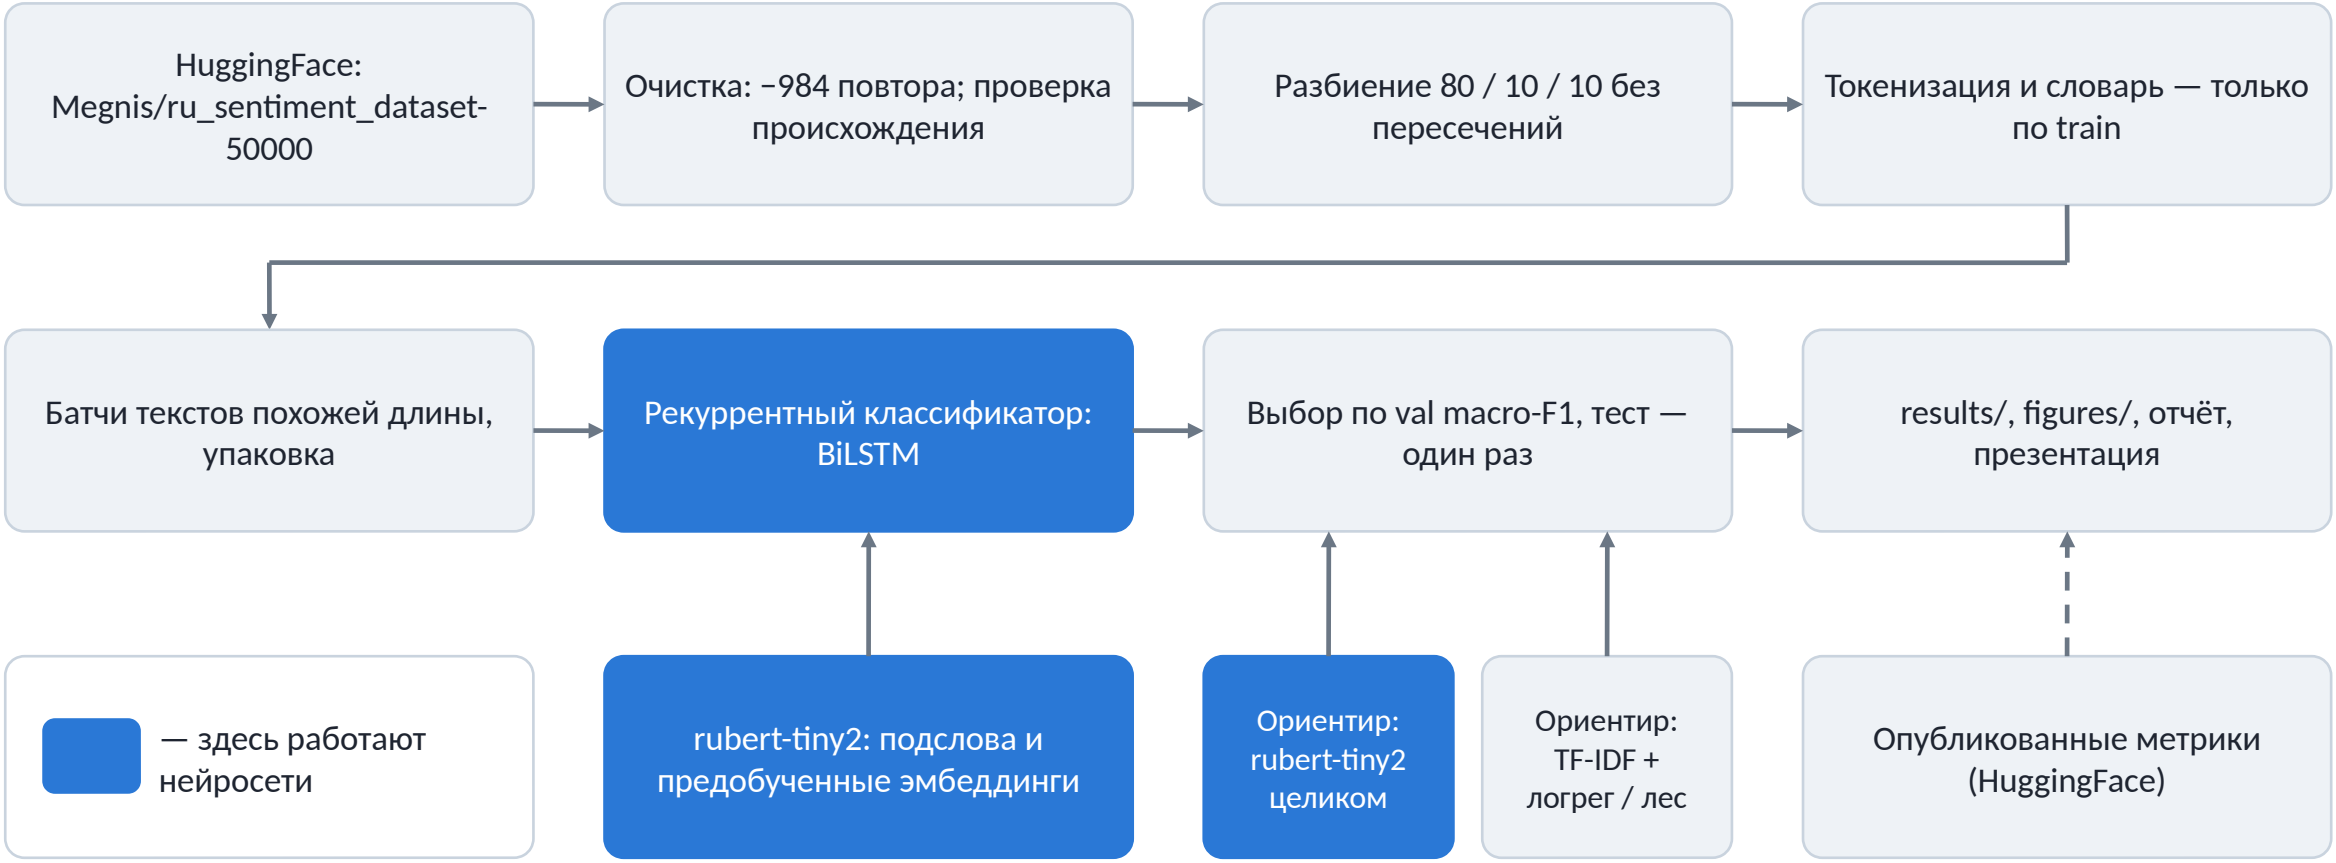
текстов длиннее 50 токенов — у них обрезка практики теряет конец

Цель и задачи

Цель: построить и обосновать рекуррентный классификатор тональности (нейтральный / позитивный / негативный) и экспериментально выяснить, какие решения влияют на качество

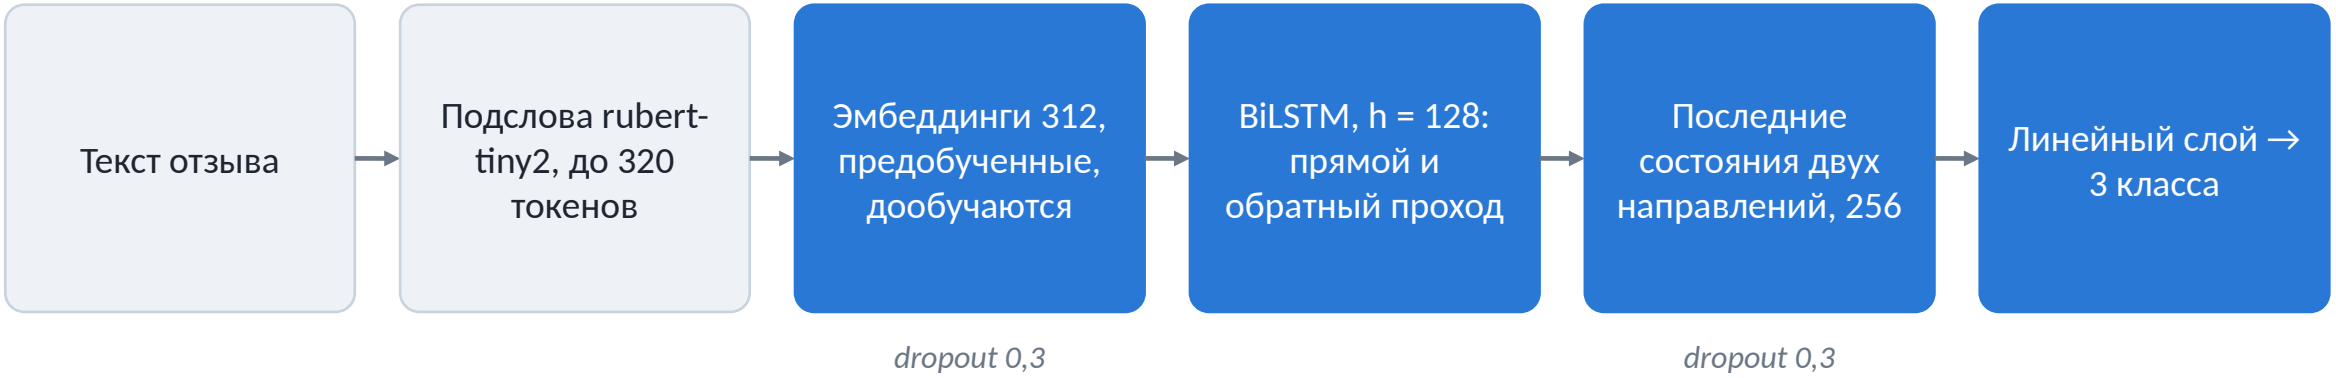
1. Описать и очистить данные, проверить происхождение набора
2. Разбить 80 / 10 / 10 без пересечений, словарь — только по train
3. Базовые модели: константа, TF-IDF + логрег, случайный лес
4. Сравнить RNN, LSTM, GRU, BiLSTM, BiGRU и длину обрезки
5. Размер скрытого состояния, число слоёв, оптимизаторы
6. Регуляризация: dropout, обрезка градиента, ранняя остановка
7. Перенос обучения: эмбеддинги и дообучение rubert-tiny2
8. Один раз оценить на тесте, разобрать ошибки, t-SNE
9. Сравнить с опубликованными метриками на HuggingFace

Структура решения и потоки данных



Тетрадка project_rusentiment_rnn.ipynb ставит эксперименты; загрузка, батчи, модель, обучение и журнал запусков — в модуле project_lib.py

Архитектура итоговой сети



20,6 млн

параметров; 20,2 млн из них — эмбеддинги 64 726 подслов

упаковка

последовательностей: состояние берётся после последнего настоящего токена, а не после нулей

инициализация

ортогональные рекуррентные матрицы, смещение забывающего вентиля LSTM = 1

Инструментарий

Python 3.13.7

язык, Jupyter-тетрадка + модуль project_lib.py

PyTorch 2.14.1

RNN / LSTM / GRU, обучение на GPU Mac (MPS)

124 мин

полный расчёт на Mac с Apple Silicon: 26 обучений сетей + базовые модели

transformers 5.19, datasets 5.1

набор данных и rubert-tiny2 с HuggingFace

scikit-learn 1.9.1

TF-IDF, логистическая регрессия, лес, метрики, t-SNE

0,116 с

шаг обучения BiLSTM на MPS против 0,158 с на CPU (батч 128, длина 100)

pandas 3.0.6, numpy 2.3.5

подготовка данных, таблицы результатов

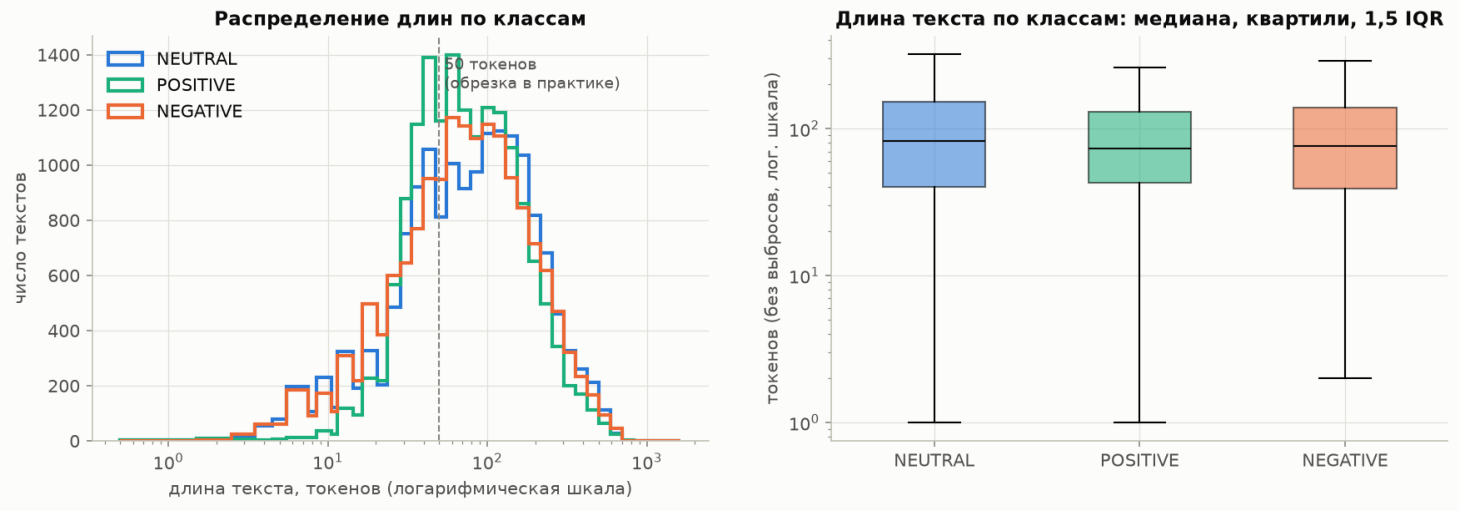
matplotlib 3.11, seaborn 0.13

все графики проекта (figures/)

$2{,}4 \cdot 10^{-7}$

максимальное расхождение RNN на MPS и CPU — проверка перед обучением

Данные: подготовка и разбиение



- Все 48 212 строк найдены в MonoHime/ru_sentiment_dataset (сплит train): совпали тексты и метки
- Повторы удалены до разбиения: 369 лишних копий и 288 групп с противоречивыми метками
- Медиана длины — 75 токенов, обрезка до 256 затрагивает 7,4 % текстов

47 228

текстов после очистки (−984)

37 782 / 4 723 / 4 723

train / val / test, классы сбалансированы

50 000 слов

словарь по train; неизвестных в val — 6,4 %

Протокол обучения и порядок экспериментов

Функция потерь: кросс-энтропия; батч 128 из текстов похожей длины; до 8 эпох

Ранняя остановка: 2 эпохи без роста val macro-F1, затем возврат лучших весов

Обрезка нормы градиента: до 1

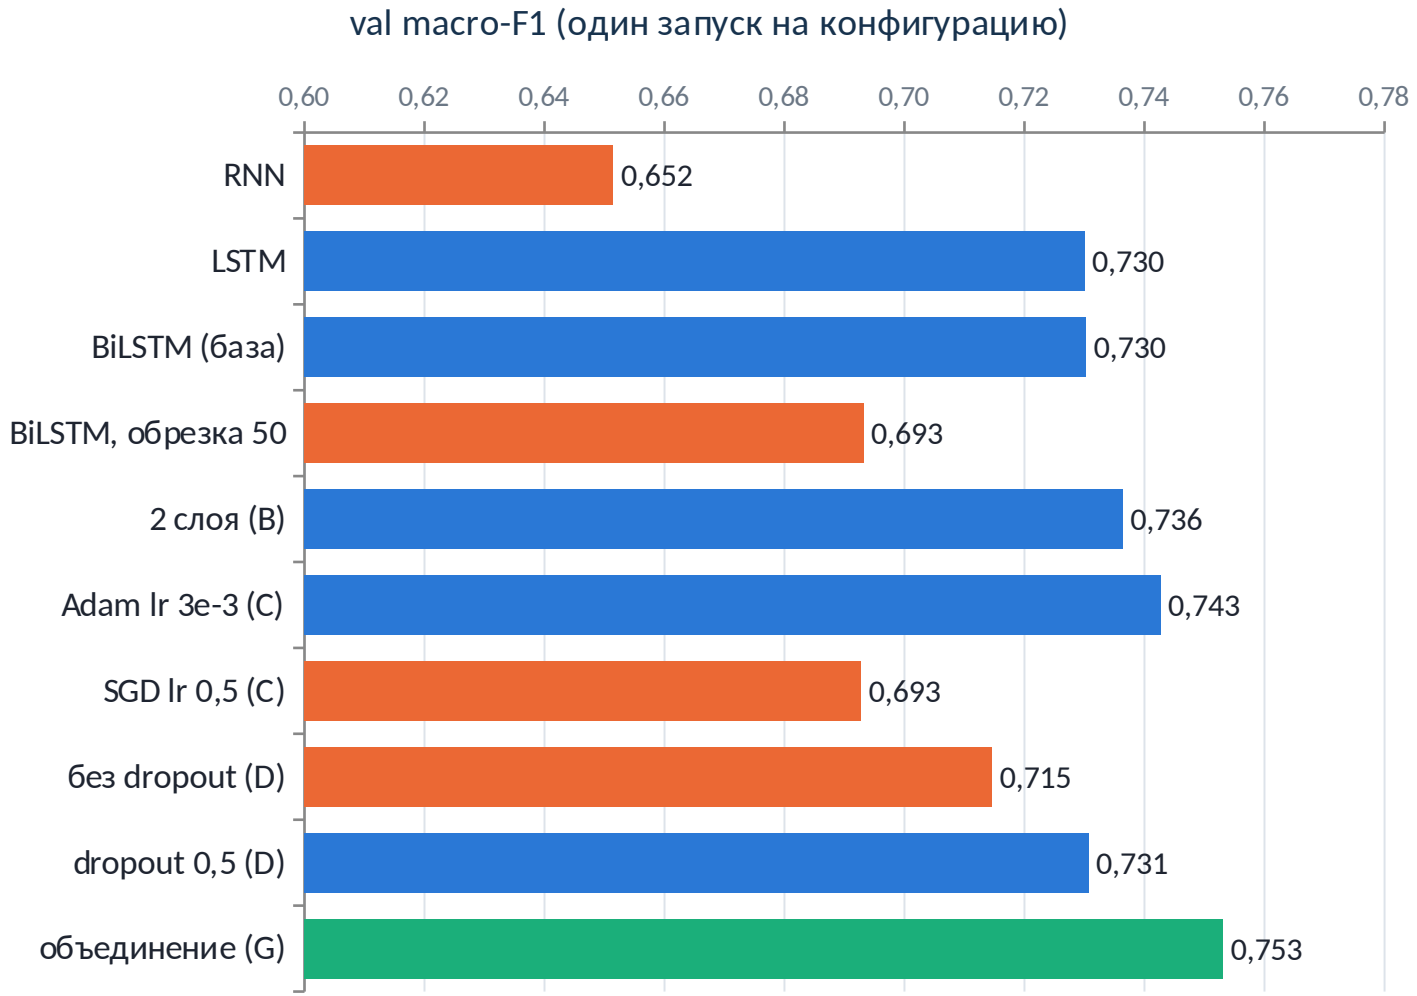
База: BiLSTM, h = 128, Adam lr = 1e-3, dropout 0,3

Метрика: macro-F1 на валидации; тест — один раз в конце

Разброс: итоговая конфигурация обучена с тремя seed (42, 43, 44)

A	тип ячейки, направленность
A2	обрезка до 50 токенов
B	размер и число слоёв
C	оптимизаторы
D	регуляризация
G	объединение лучших решений
E	предобученные эмбеддинги
F	rubert-tiny2 целиком (ориентир)

Этапы A–G: что влияет на качество



Вентили: +8 п. п. к простой RNN

Длина 256 вместо 50: +3,7 п. п.

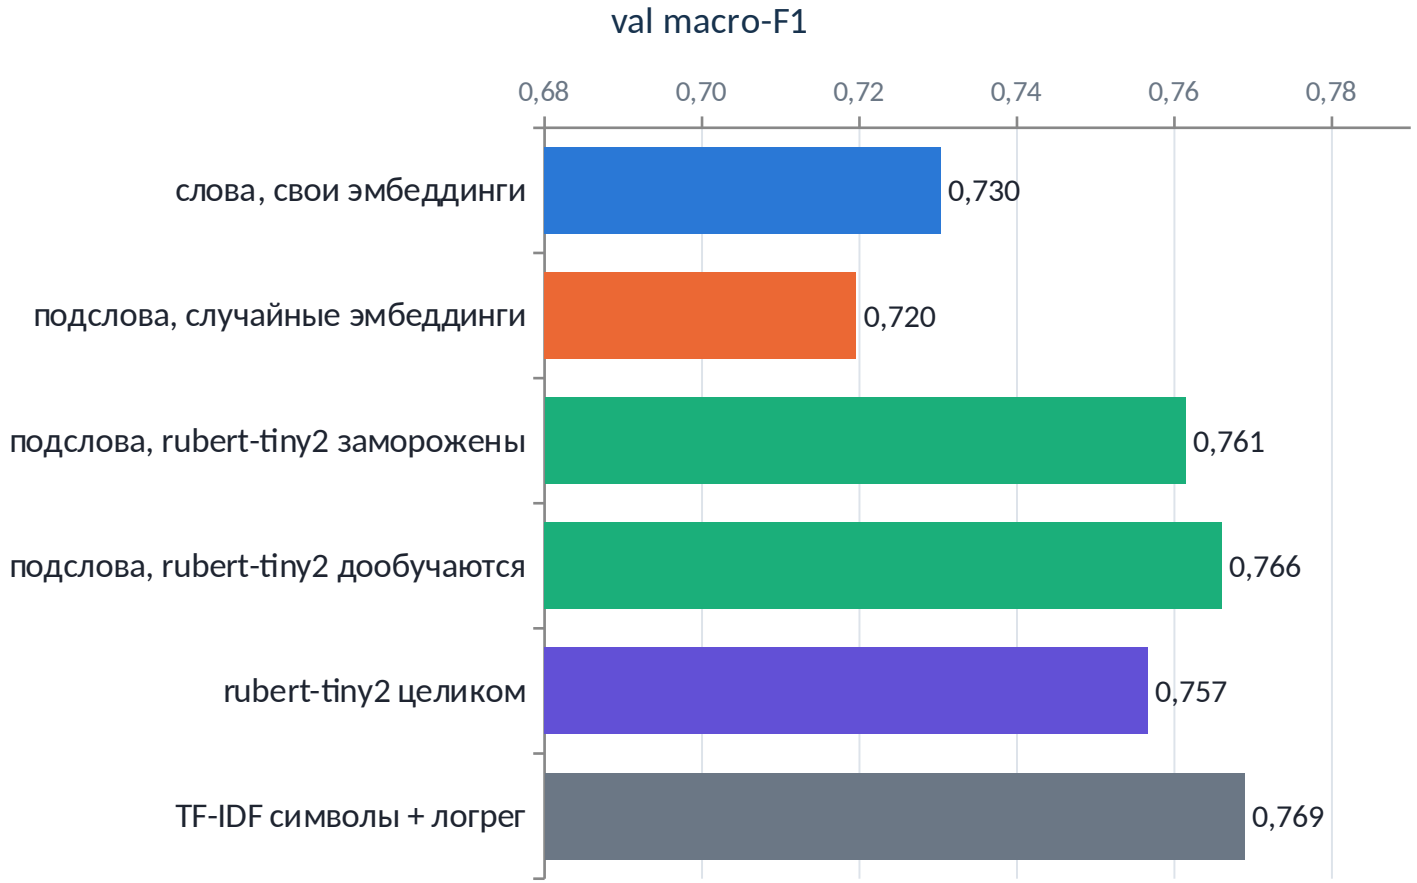
Оптимизатор и lr: до 5 п. п.; Adam 3e-3 — лучший

Dropout: +1,5 п. п., меньше переобучение

Объединение B + C + D: 0,753, +2,3 п. п. к базе

На уровне шума (± 0,004): двунаправленность, h > 128, dropout 0,3 / 0,5, обрезка градиента

Перенос обучения: готовая сеть rubert-tiny2



cointegrated/rubert-tiny2
компактный русскоязычный BERT: 29,2 млн параметров, эмбеддинги 312, словарь 83 828 подслов. Берём токенизатор и матрицу эмбеддингов; для ориентира дообучаем целиком (3 эпохи, 128 подслов, lr 2e-5)

- Сам токенизатор не помогает (0,720): выигрыш даёт только предобучение
- Замороженные эмбеддинги: +3,1 п. п., 0,45 млн обучаемых параметров, 24 с на эпоху
- rubert-tiny2 целиком отстаёт: у 43 % текстов отрезан конец (128 подслов)

Серый — лучшая базовая модель (классический ориентир).

Итоговая модель и гиперпараметры

Токенизация	подслова rubert-tiny2, до 320 токенов
Эмбеддинги	312, предобученные, дообучаются
Рекуррентный слой	BiLSTM, 1 слой, h = 128
Dropout	0,3
Оптимизатор	Adam, lr = 1e-3, обрезка градиента 1
Обучение	батч 128, до 8 эпох, ранняя остановка
Выбрана эпоха	3-я (seed 42)

0,769 ± 0,004

val macro-F1 по трём seed (0,766 / 0,773 / 0,767)

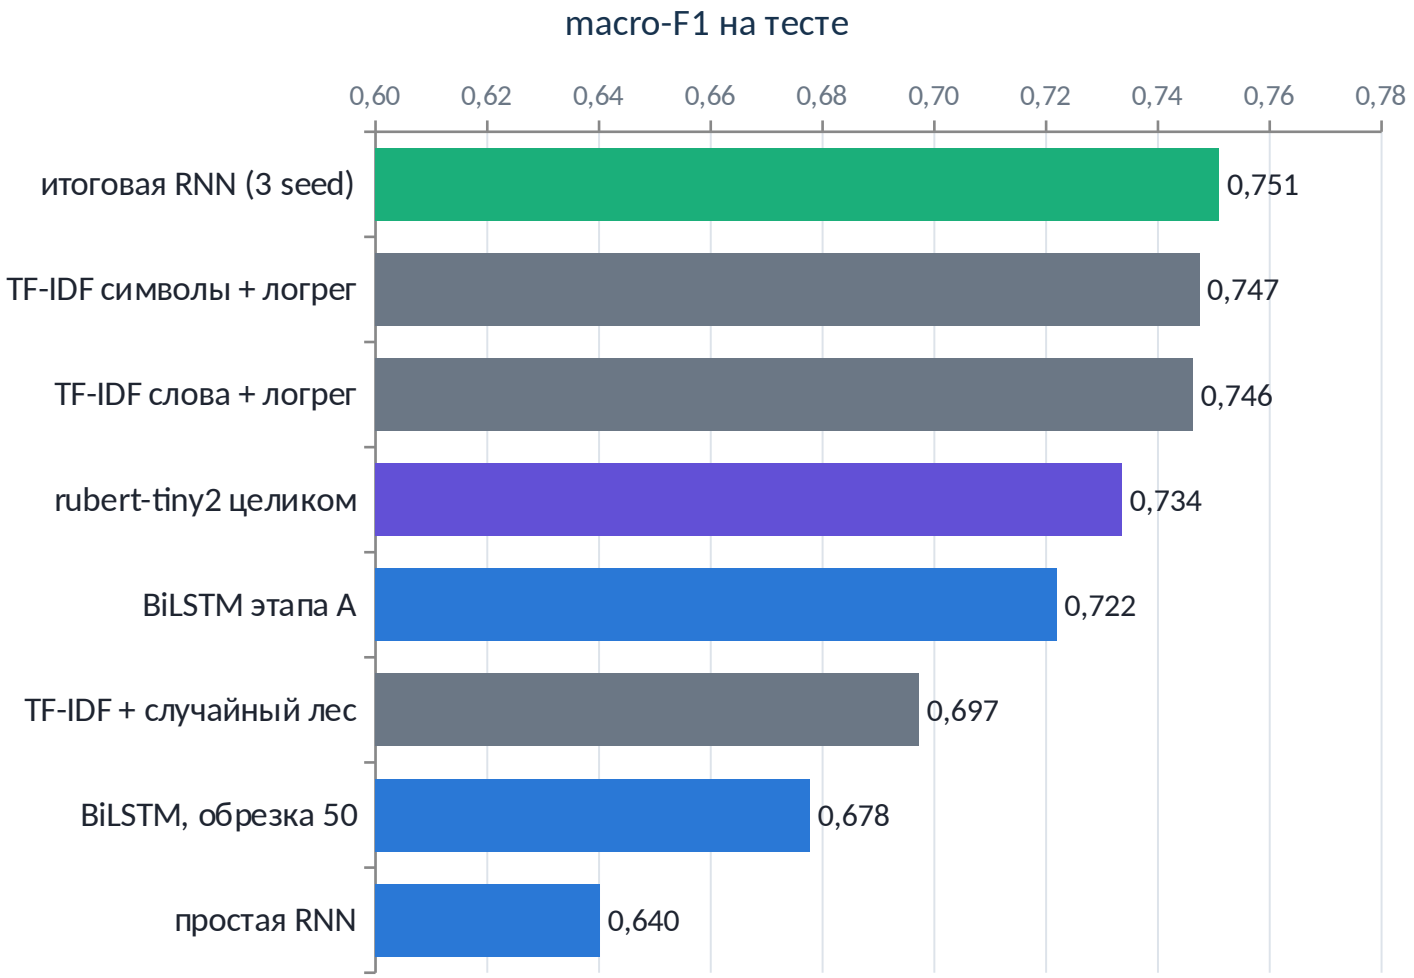
23

конфигурации сравнены по валидации

75 с

на эпоху на MPS; замороженный вариант — 24 с

Результаты на тесте (4 723 текста)



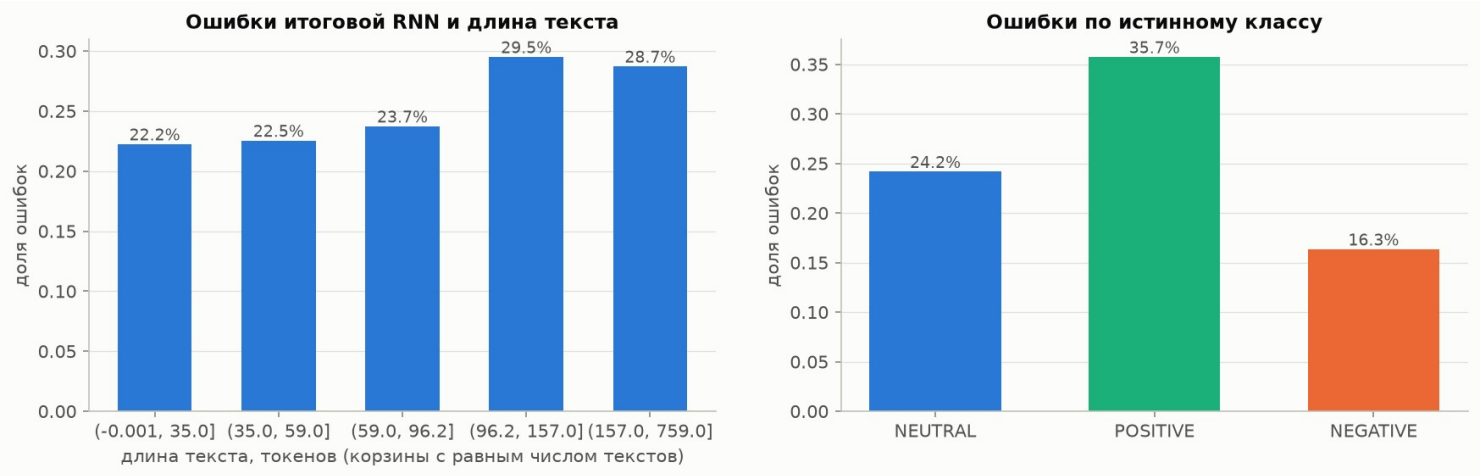
0,751 ± 0,006

macro-F1 итоговой модели; accuracy 0,752 ± 0,005

- +2,9 п. п. к BiLSTM этапа A, +7 п. п. к обрезке до 50 токенов
- Лучше дообученной rubert-tiny2 на 1,1–1,7 п. п.
- Символьный TF-IDF (0,747) не уступает: разница меньше разброса по seed
- Тест ниже валидации (0,751 против 0,769): выбор лучшей из 23 конфигураций делает оценку по валидации оптимистичной

Где ошибается модель





Положительный → нейтральный: 24–25 % положительных текстов у всех трёх моделей — свойство данных, а не модели

Длинные тексты: 29–30 % ошибок против 22–24 % у коротких

По классам: POSITIVE — 36 % ошибок, NEGATIVE — 16 %

Трудные тексты: на 14,4 % теста ошибаются все три сильные модели

Проблемные и корректные примеры

Проблемные

метка POSITIVE → модель NEGATIVE (p = 1,00)
«Не водите своего ребёнка к педиатру… не лечит, а калечит» — похоже на ошибку разметки

метка NEGATIVE → модель POSITIVE (p = 1,00)
«ОГРОМНОЕ СПАСИБО за нашего сына…» — тоже ошибка разметки

метка NEUTRAL → модель NEGATIVE (p = 0,99)
новость о гибели ребёнка: тон нейтральный, тема негативная — разные правила разметки

Ирония «Ну спасибо за „прекрасный“ сервис…»
RNN: NEGATIVE (0,60), rubert-tiny2: POSITIVE (0,45)

Корректные

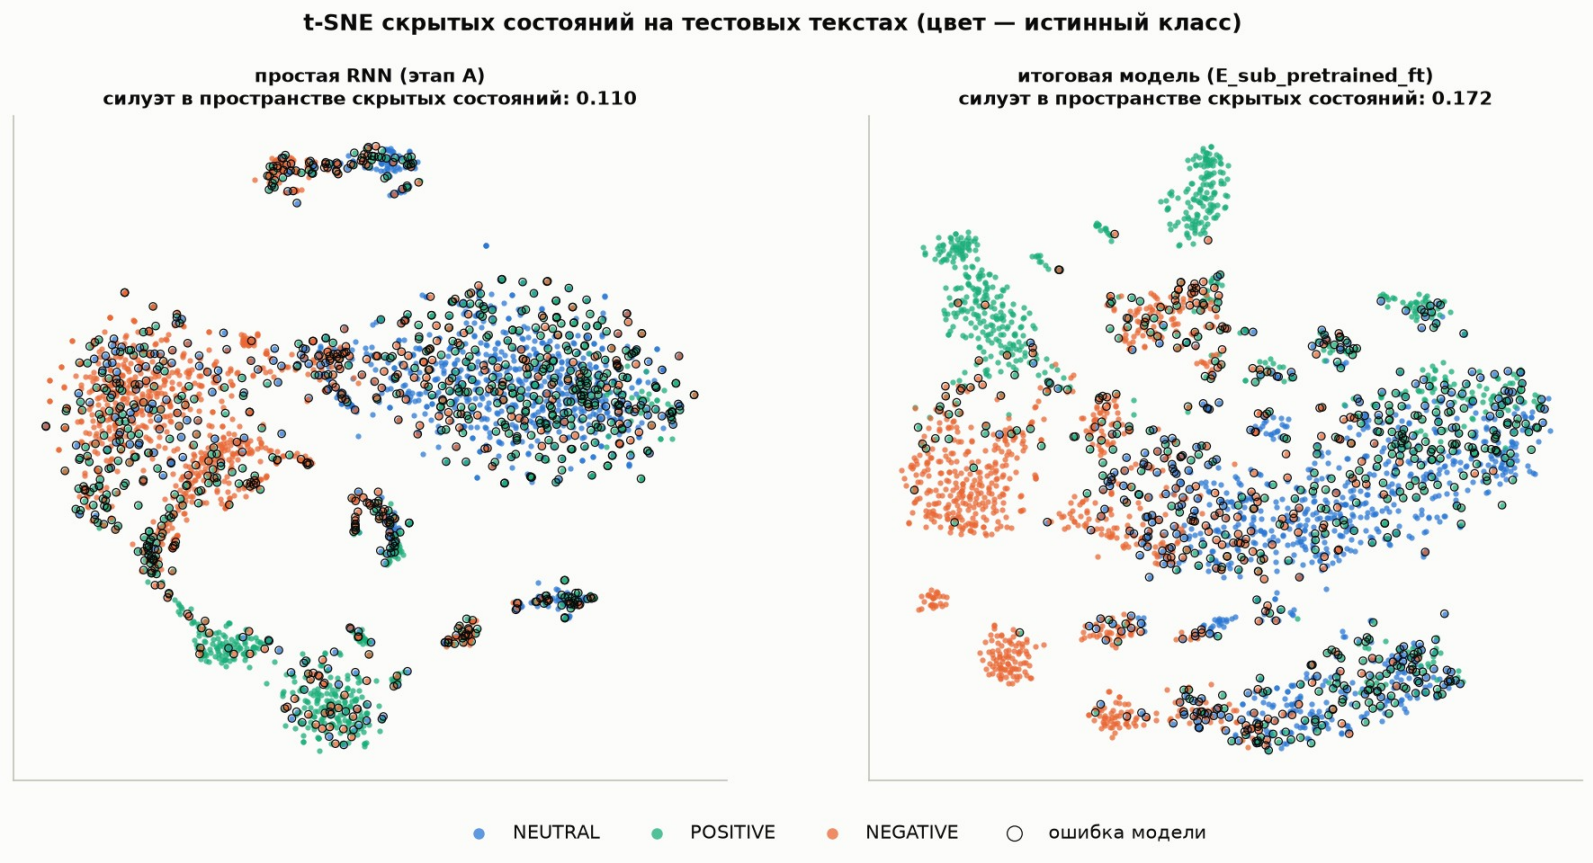
POSITIVE (p = 1,00)
благодарность врачу: «Спасибо Вам огромное за помощь в лечении моего ребёнка!»

NEGATIVE (p = 1,00)
«Плохое отношение к клиентам. Мало того, что не отпускают лекарства по рецептам…»

NEUTRAL (p = 0,96)
«В целом неплохо, но старая мебель и некачественная уборка подпортили впечатления…»

Свои фразы
явный позитив, негатив и нейтральное описание — верно, p 0,93–0,99

Скрытые состояния сети (t-SNE)

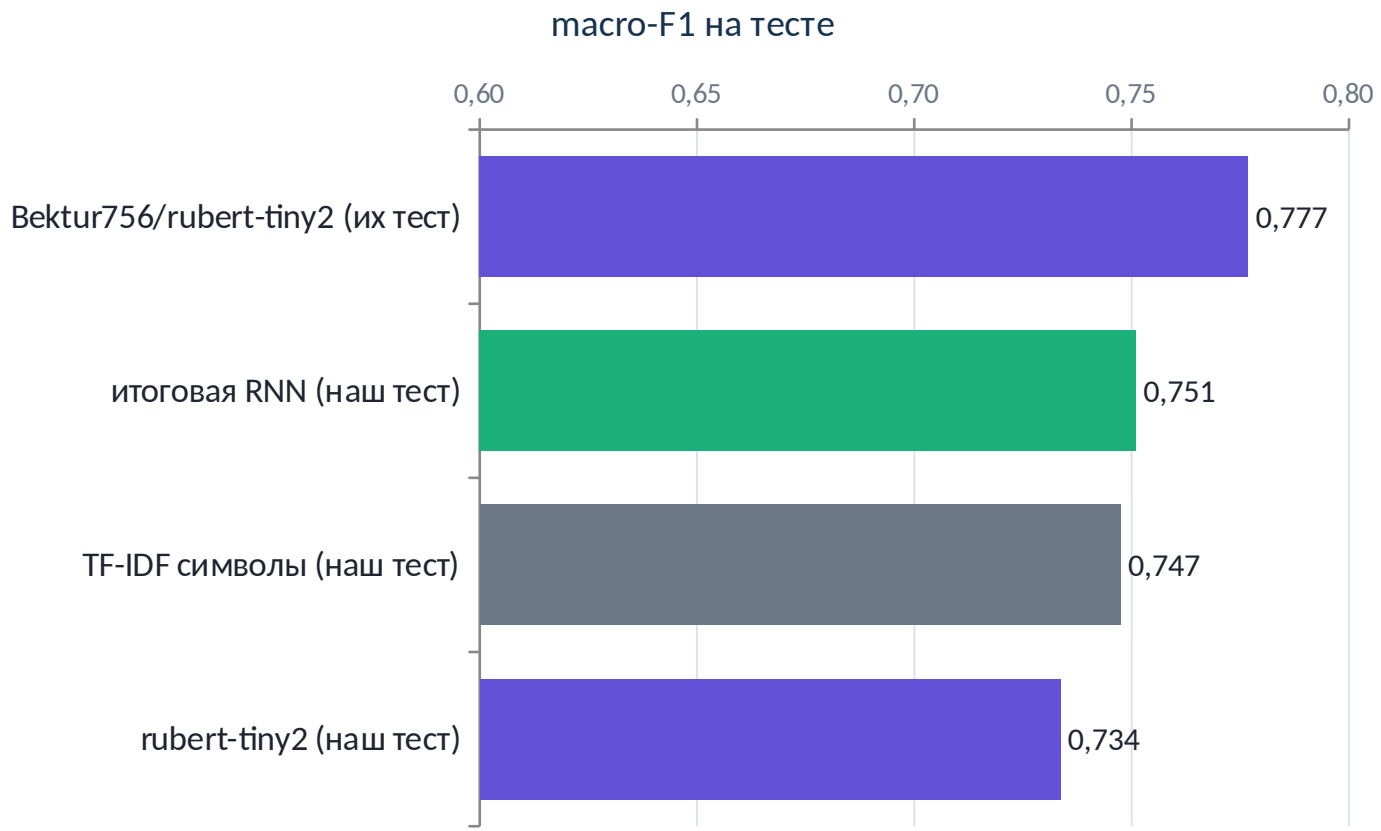


0,110 → 0,172

силуэт: простая RNN → итоговая модель

- Отрицательный и положительный классы образуют компактные группы
- Нейтральный в центре смешан с обоими
- Ошибки — в зонах перемешивания: кандидаты на проверку разметки

Сравнение с опубликованными результатами



- Для самого набора опубликованных метрик нет; ближайший ориентир — модель на исходном наборе MonoHime
- У неё в 4,8 раза больше обучающих текстов (180 853) и другой, несбалансированный тест — сравнение только ориентировочное
- Распределение по классам то же: лучше всего — NEGATIVE
- 0,99 из практики 10 — следствие утечки; та же BiLSTM без утечки даёт 0,722

Опубликованные модели, по-видимому, видели наши тексты при обучении, поэтому для прямого сравнения rubert-tiny2 дообучена заново на наших данных.

Заключение

- Итоговая модель — BiLSTM на подсловах с дообучаемыми эмбеддингами rubert-tiny2: macro-F1 на тесте 0,751 ± 0,006
- Сильнее всего влияют вентили (+8 п. п.), длина текста (+3,7), предобученные эмбеддинги (+3–4) и скорость обучения (до 5)
- Двунаправленность, размер сети сверх h = 128 и второй слой — в пределах шума
- Сильная классическая модель (символьный TF-IDF, 0,747) не уступает: разметка шумная, граница «позитив — нейтрально» размыта
- Дальше: обучить на всём исходном наборе (в 4–5 раз больше), почистить разметку, объединить RNN и TF-IDF в ансамбль